코디세이 AI 해커톤 2026 · 팀 프리덤

AI 프롬프트 개인정보 보호 시스템

어떤 LLM 서비스에도 끼워 넣는 한국어 보안 계층

프리덤 팀

이진걸 주재문 김승우

문제 정의 및 목표 사용자

AI가 경고할 때, 데이터는 이미 서버에 있습니다

1. 프롬프트 입력
코드, 로그, 고객 정보가 함께 입력됩니다

→

2. LLM 서버 도착
이 순간 데이터는 이미 조직 밖에 있습니다

→

3. 그제야 나오는 경고
모델이 알아채도 전송을 되돌릴 수 없습니다

79%
직장인이 로그인 정보 같은 민감정보를 AI에 입력한 경험 (Zapier 설문, 2026)

2023
삼성전자, 내부 코드 유출 후 생성형 AI 사용 제한

2025
개인정보위, 딥시크에 국외 이전된 프롬프트 파기 권고

목표 사용자 **기업 개발팀**과 보안 담당자, 그리고 AI 코딩 도구를 쓰는 개인 개발자

출처: Zapier 설문(2026, 1,005명), CSO Online(2023), 뉴시스(2025.4.24)

해결 방안: 서비스 개요

어떤 AI 서비스든, 전송 전에 한 번 더 검사합니다

AI 서비스

Codex
지원 중

Claude Code
확장 예정

사내 챗봇·RAG
확장 예정

연결 방식

플러그인 훅
입력·도구 결과

로컬 프록시
요청·응답 전체

검사 API
서비스 독립 호출

보호 계층

규칙 엔진
작동 중

자체 학습 모델
GPU 인수 통과, 교체 승인

정책과 기록
차단 · 마스킹 · 사건 기록

외부 LLM

검사를 통과한 내용만 전달

같은 정책과 탐지 코드를 **훅과 프록시 두 방식으로 이미 연결**했습니다. 서비스가 늘어도 연결부만 추가하면 됩니다.

주요 기능

전송 전에 막고, 무엇을 막았는지 보여줍니다

사용자 입력
주민번호·카드·API 키는 차단, 이메일·전화는 전송을 멈추고 가린 문장 안내

파일·명령 결과
LLM에 가기 전 안내문이나 가린 내용으로 대체

LLM 응답
프록시는 표시 전 검사, 플러그인은 표시 후 기록과 재요청

차단 사건 대시보드
차단·중단·사후 건수와 운영 현황을 브라우저에 실시간 표시

시연 예시 · 가상 데이터

› 주민번호 900101-1234567 확인해줘

차단: 전송되지 않음

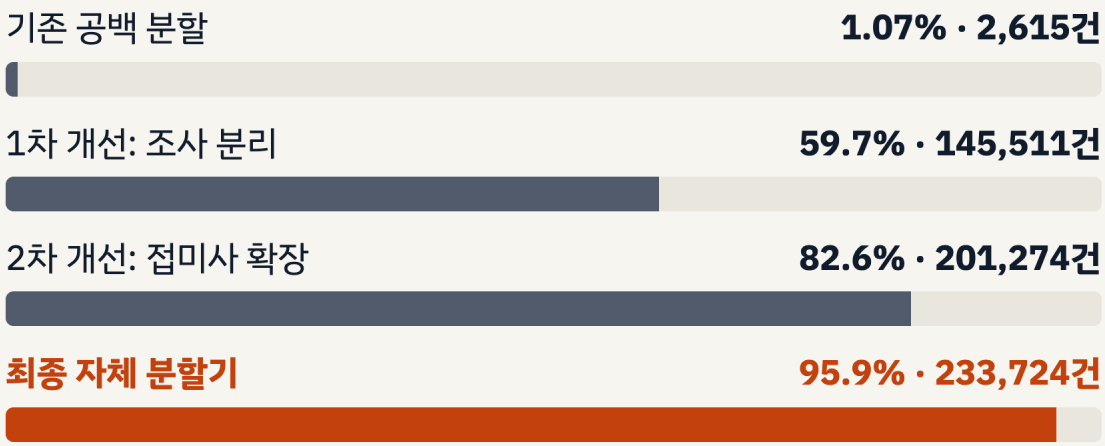
› 메일 user@example.com 로 보내줘

중단: 가린 문장 안내

검사가 실패해도 내용을 보내지 않습니다

직접 개발 범위

한국어 조금 더 특화된 모델을 만들고자 했습니다.



우리가 만든 것

한국어 분할기
원문과 정답을 바꾸지 않고 경계 분리

정답 변환 파이프라인
역변환 실패 0건, 유형 소실 7종 → 0종

평가 체계
18개 유형, 독립 시험셋 300건

모델 교체 판정 게이트
재현율·F1·오차단율 자동 판정

학습 문서 243,711건 중 중복을 제외한 표현 가능 문서 수

활용 AI 기술

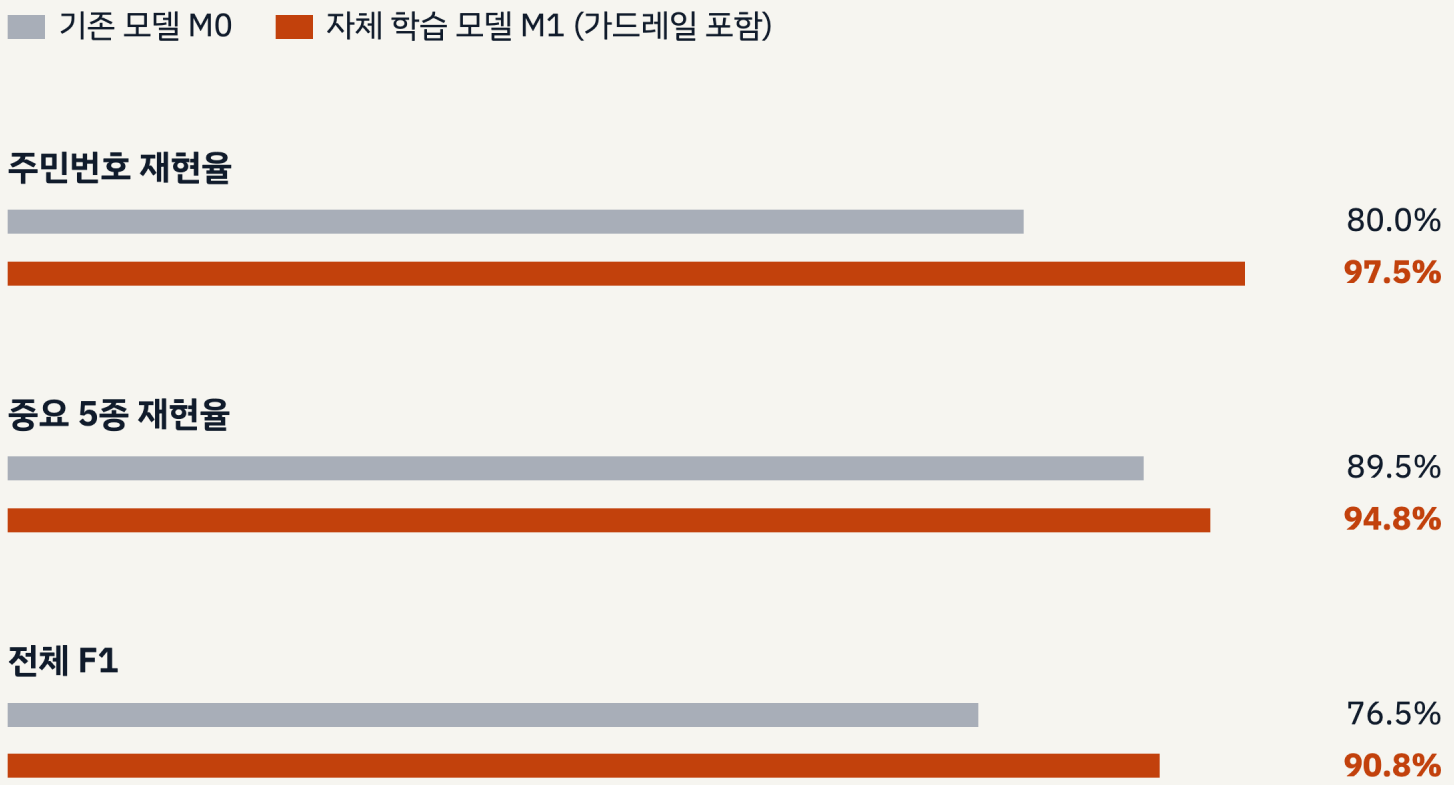
GPU 서버에서 직접 학습해 한국어 탐지를 끌어올렸습니다

알고리즘
GLiNER 개체 탐지, mDeBERTa-v3 파인 튜닝

GPU
NVIDIA L4 24GB

데이터
K-PII-Bench 5,000건, 2 epoch

학습 손실
71.15 → 1.22



교체 승인: 교체 기준 5개를 모두 통과했고, 정상 문서 오차단은 0/100입니다.

서비스 시험 300건 기준, 가드레일 전 전체 F1 89.4%. 공식 Test 28,142건 전체 F1은 66.6% → 98.7%

개발 환경 및 기술 스택

일반 서버와 GPU 서버를 모두 사용했습니다.

영역	기술
언어	Python 3.12
AI·학습	PyTorch 2.10, GLiNER 0.2.29, Transformers 4.57
서버·API	FastAPI, Uvicorn, Pydantic, HTTPX, HTTPS 토큰 인증
사용자 PC	Codex 플러그인 훅, 로컬 프록시, 로컬 대시보드, PyInstaller
인프라	주최 측 제공 GPU 서버(NVIDIA L4 24GB, Ubuntu 24.04), systemd
품질	pytest, Hypothesis, 회귀·악조건 테스트

팀원별 역할 분담

이진걸

모델 학습·평가

한국어 분할기
데이터 변환
GPU 파인튜닝
평가 체계와 판정 게이트
Codex 플러그인 공동 작업

주재문

게이트웨이·검사 API·배포

양방향 검사와 정책 엔진
GPU API 배포와 TLS
Mac 배포 패키지
통합 검증
Codex 플러그인 공동 작업

김승우

대시보드

차단 사건 대시보드
운영 현황 시각화
프로젝트 문서화
Codex 플러그인 공동 작업

외부 자원 활용 내역

구분	명칭	용도	라이선스
오픈소스	GLiNER 0.2.29	개체 탐지 프레임워크	Apache-2.0
오픈소스	urchade/gliner_multi_pii-v1	파인튜닝 기반 모델	Apache-2.0
오픈소스	microsoft/mdeberta-v3-base	백본 모델	MIT
오픈소스	PyTorch, Transformers, Accelerate, SentencePiece	학습·추론	BSD 계열, Apache-2.0
오픈소스	FastAPI, Starlette, Uvicorn, Pydantic, HTTPX	서버·통신	MIT, BSD-3-Clause
오픈소스	pytest, Hypothesis, PyInstaller	테스트·패키징	MIT, MPL-2.0, GPL-2.0(예외 조항)
오픈소스	OpenAI Codex CLI	보호 대상 CLI	Apache-2.0
외부 API	OpenAI API	프록시 경로 LLM 호출	상용 API
사전 보유 코드	없음	해당 없음	해당 없음
기타	K-PII-Bench	학습·평가 데이터	CC BY 4.0
기타	townboy/korean-pii-dataset	후보 검증, 미채택	CC BY 4.0
기타	네이버 클라우드 GPU 서버	학습·추론	주최 측 제공
기타	Claude Code, Codex, Antigravity	AI 개발 도구	상용 서비스

이 밖의 하위 의존 패키지는 저장소의 환경·잠금 파일에 기록했습니다.

K-PII-Bench: Woohyun Park, Jinyoung Oh, Jeong-Won Cha, Changwon National University, 2026. 변환·표본 추출하여 사용

기대 효과

금지 대신 안전한 사용

AI를 막지 않고 기밀을 지킵니다

전면 금지 대신 민감한 값만 전송 전에 걸러냅니다.

기존 서비스에 그대로 끼웁니다

쓰던 도구를 바꾸지 않고 플러그인 설치로 시작합니다.

감사 근거를 남깁니다

원문 대신 유형과 조치를 기록해 대시보드로 확인합니다.

적용 가능성: 규칙 검사는 Python 패키지 설치나 별도 설정 없이 바로 동작합니다.

macOS, Codex CLI 0.166.0 격리 환경과 모의 LLM으로 검증. 규칙 검사는 대표 형식을 탐지합니다.

확장 가능성

Codex에서 시작해 모든 AI 접점으로

완료

Codex 보호

플러그인 훅
규칙 엔진
로컬 대시보드
GPU 검사 API
자체 학습 모델 인수

다음 단계

모델 고도화

오탐 유도 문서 재학습
직책·질병 유형 보강
플러그인에 모델 연결

서비스 확장

연결 대상 확대

Claude Code
사내 챗봇·상담봇
RAG 파이프라인

조직 확장

중앙 관리

사건 중앙 수집
조직별 정책 관리
계정과 권한

AI 사용을 막지 않으면서, 나가면 안 되는 정보만 멈춰 세웁니다.